

Trabalho Prático 2 - Algoritmo de Colônia de Formigas para o problema da p-Mediana

Hugo Araujo de Sousa

Computação Natural (2017/2)
Departamento de Ciência da Computação
Universidade Federal de Minas Gerais (UFMG)

`hugosousa@dcc.ufmg.br`

Resumo. *Este trabalho tem como objetivo o desenvolvimento de conceitos fundamentais na aplicação do Algoritmo de Colônia de Formigas (Ant Colony Optimization - ACO) para resolução do problema da p-Mediana. A estrutura básica do ACO é apresentada e adaptada ao problema a ser resolvido. Finalmente, a partir de dados de teste, são realizados experimentos e a análise dos resultados obtidos.*

1. INTRODUÇÃO

Como definido por [Brownlee 2011], o Algoritmo de Colônia de Formigas é um método dos campos de Inteligência de Enxames, Metaheurísticas e Inteligência Computacional. Nesse método, o comportamento de formigas na natureza, em particular a comunicação baseada em feromônio que elas realizam para encontrar bons caminhos na busca por comida em um ambiente, é inspiração para encontrar potenciais soluções para um problema.

Na busca por comida, formigas se espalham inicialmente aleatoriamente em seu ambiente. Uma vez que uma fonte de comida é localizada, as formigas que a encontraram começam a depositar feromônio nesse ambiente, marcando assim o caminho que as levaram até a fonte. Quando várias um mesmo caminho é percorrido várias vezes e por várias formigas, a quantidade de feromônio nesse caminho se torna notavelmente maior do que em outras partes do ambiente, enquanto caminhos pouco percorridos perdem feromônio à medida que o tempo passa, devido à evaporação do mesmo. A comunicação das formigas, e ponto fundamental para o algoritmo, ocorre através do feromônio depositado, uma vez que elas tendem a seguir por caminhos com maior quantidade de feromônio.

Usando esse comportamento como inspiração, surge o Algoritmo de Colônia de Formigas, cuja estratégia geral é a de construir soluções candidatas para um problema de forma estocástica. Essas soluções são construídas, então, de forma probabilística e têm suas qualidades avaliadas. A partir dessas medidas de qualidade, 'feromônio' é depositado nos caminhos que geraram soluções de maior qualidade e, dessa forma, novas soluções criadas tendem a seguir pelos mesmos caminhos.

Nesse trabalho, o Algoritmo de Colônia de Formigas será utilizado para resolver o problema da p-Mediana com restrições de capacidade. Esse problema consiste em decidir onde localizar p centros em uma rede (composta por vértices e arestas) de forma a minimizar a soma de todas as distâncias de cada vértice ao centro mais próximo. Nesse problema também existem restrições de capacidade de atendimento dos centros. Esse problema é um problema de otimização combinatória NP-difícil.




Figura 1. Ilustração do problema da p-Mediana. Na imagem, vemos os centros (círculos) sendo atendidos pelas medianas (centros em preto). A relação de atendimento entre um centro e uma mediana é representada pelas linhas tracejadas.

2. MODELAGEM

Para utilizar o Algoritmo de Colônia de Formiga para o problema da p-Mediana, é necessário realizar uma modelagem relativa à construção de soluções, comportamento de formigas, depósito de feromônio, entre outros aspectos. No trabalho em questão, a modelagem seguiu em grande parte [de França et al. 2005].

Mais formalmente, podemos definir o problema da seguinte forma:

1. Seja n o número de centros.
2. Seja p o número de medianas a serem selecionadas.
3. Seja a_i a demanda do centro i .
4. Seja c_j a capacidade da mediana j .
5. Seja d a matriz de dimensão $n \times n$ onde d_{ij} representa a distância entre os centros i e j .
6. Seja x a matriz de dimensão $n \times p$ onde $x_{ij} = 1$ se o centro i é atendido pela mediana j e 0 caso contrário.
7. Dessa forma, o problema da p-Mediana trata-se do problema de minimizar $\sum_{i=1}^n \sum_{j=1}^p d_{ij} x_{ij}$, considerando algumas restrições:
 - (a) $\sum_{i=1}^n x_{ij} = 1, j = 1, \dots, p.$
 - (b) $\sum_{i=1}^n x_{ij} a_i \leq c_j, j = 1, \dots, p.$

2.1. Algoritmo

A estrutura geral do Algoritmo de Colônia de Formigas é apresentada na listagem a seguir. Percebemos que trata-se de um algoritmo simples a alto nível, sendo cada um de seus procedimentos internos variados de acordo com o problema em questão.

```
1  Procedimento ACF() :
2      Enquanto iter < max_it Faça:
3          Para cada formiga Faça:
4              constroi_solução()
5              atualiza_feromônio()
6          Fim Para
7      Fim Enquanto
8  Fim
```

Listagem 1: Pseudocódigo para o Algoritmo de Colônia de Formigas. *iter* se refere a iteração atual e *max_it* ao número total de iterações a serem executadas.

Na Listagem 1, o procedimento **constroi_solução()** constrói uma solução para o problema tendo como base as quantidades de feromônio e outras heurísticas opcionais. Cada formiga passa por um centro a cada passo de uma iteração. Já o procedimento **atualiza_feromônio()** utiliza a informação de qualidade de cada solução construída e atualiza as quantidades de feromônio depositadas.

2.2. Feromônio

Na implementação desse trabalho, como sugerido em [de França et al. 2005], os níveis de feromônio são referentes aos centros. Dessa forma, um vetor τ armazena a quantidade de feromônio depositada em cada centro.

Dessa forma, durante a etapa de construção de soluções, as formigas escolhem probabilisticamente os centros que servirão de mediana com base na quantidade de feromônio presente em cada um. Como decisão de implementação, os níveis de feromônio só são atualizados por formigas que geraram soluções ótimas locais ou globais. A fórmula que determina como é feita a atualização dos níveis de feromônio com base em uma solução S é:

$$\tau_i = \rho * \tau_i + \Delta\tau_i$$

Onde ρ representa a taxa de evaporação do feromônio τ_i já presente em um centro i e $\Delta\tau_i$ é dado por:

$$\Delta\tau_i = \frac{1}{f(S)}$$

se $i \in S$, 0 caso contrário. $f(S)$ é uma função que retorna a qualidade da solução S . Para isso, o custo da solução S é normalizado no intervalo entre o custo da melhor solução encontrada até o momento e o custo da pior, sendo o primeiro equivalente a 1 e o segundo a 0.

2.3. Construção de Soluções

Para construir soluções, as formigas consideram o nível de feromônio presente nos centros. Com esses níveis, existe uma probabilidade associada à escolha de cada centro pelas formigas, que escolhem os p centros que serão medianas um por um, considerando a probabilidade dada por:

$$p_i^k(t) = \frac{\tau_i(t)^\alpha * \eta_i^\beta}{\sum_{i \in J^k} \tau_i(t)^\alpha * \eta_i^\beta}$$

se $i \in J^k$, onde J^k é a lista de centros ainda não escolhidos pela formiga k , η_i é uma função heurística descrita na Seção 2.4 e α e β são parâmetros de peso do feromônio e da heurística, definidos pelo usuário. Caso $i \notin J^k$, $p_i^k(t) = 0$.

Após a seleção de p centros para serem medianas, cada um dos $n - p$ centros restantes devem ser alocados a precisamente uma mediana. Para isso, uma heurística definida em [de França et al. 2005] é utilizada, sendo uma instância do Problema de Alocação Generalizada (tradução livre de Generalized Assignment Problem - GAP). O Pseudocódigo que descreve a heurística é apresentado na Listagem 2.

```
1  Procedimento GAP(centros, medianas, n, p):
2    x = Matriz (n x n) inicializada com 0
3    centros_ordenados = ordena_centros()
4
5    Para i de 1 até n Faça:
6      medianas_ordenadas = ordena_medianas(centros_ordenados[i])
7
8    Para j de 1 até p Faça:
9      Se (capacidade(medianas_ordenadas[j]) - demanda(centros_ordenados[i]) >= 0) Faça
10       x[centros_ordenados[i]][medianas_ordenadas[j]] = 1
11     Fim Se
12   Fim Para
13 Fim Para
14 Fim
```

Listagem 2: Pseudocódigo para a heurística do GAP. O procedimento `centros_ordenados()` gera uma lista com todos os n centros em ordem crescente de distância a suas correspondentes medianas mais próximas. O procedimento `ordena_medianas()` gera uma lista com todas as p medianas em ordem crescente de distância ao centro passado como parâmetro.

2.4. Heurística de Informação

Para melhorar as soluções construídas pelas formigas, [de França et al. 2005] sugere a implementação de uma heurística que considera a qualidade da escolha de cada centro como parte da solução.

Nessa heurística, a informação de distância entre o centro sendo analisado e o restante é necessária. Aqui, a ideia é calcular a densidade otimista dos centros se um dado centro fosse escolhido como mediana. O algoritmo da heurística é mostrado na Listagem 2.

```

1  Procedimento InfHeur(centro):
2      centros_ordenados = ordena_centros(centro)
3      todos_centros, soma_distância = aloca(centro, centros_ordenados)
4      densidade = (todos_centros) / (soma_distância)
5
6      Retorna densidade
7  Fim

```

Listagem 3: Pseudocódigo para a Heurística de Informação implementada. O procedimento `ordena_centros(centro)` ordena todos os centros com base na distância entre eles e o centro passado como parâmetro. O procedimento `aloca(centro, centros_ordenados)` associa cada centro em `centros_ordenados` ao centro passado como parâmetro, até que sua capacidade seja atingida, retornando dois valores: (i) `todos_centros`: o número de centros alocados com sucesso; e (ii) `soma_distância`: a soma de todas as distâncias entre os centros alocados e o centro passado como parâmetro.

3. IMPLEMENTAÇÃO

Seguindo a modelagem do problema mostrada na Seção 2, o programa foi implementado utilizando a linguagem Python 3¹. O programa utiliza intensivamente a módulo NumPy² da linguagem, principalmente para a geração de números aleatórios. As classes desenvolvidas e a estrutura do código fonte são apresentadas a seguir.

- Classe **Client**, arquivo `client.py`. Define um centro presente no espaço. Para isso, armazena as informações de coordenadas, demanda e capacidade (para centros escolhidos como medianas).
- Arquivo **tp2.py**. Define o programa principal com os parâmetros de linha de comando e entrada e saída.
- Classe **ACO**, arquivo `aco.py`. Define uma instância do problema de p-Mediana como otimização por colônia de formigas. Armazena todas as informações como número de centros, medianas, vetor de feromônio, valores máximos e mínimos para feromônio, melhor solução global, etc.

Algumas decisões de implementação importantes são apresentadas a seguir:

- A fim de evitar que os valores de feromônio tendam a se tornarem arbitrariamente grandes (ou pequenos), foram definidos valores de feromônio mínimo e máximo. O valor mínimo é 0.001 e o máximo é 0.999.
- O valor inicial de feromônio presente em todos os centros é definido como 0.5, seguindo [de França et al. 2005].
- Uma política para evitar que o algoritmo fique estagnado é implementada, também tendo como referência o que é feito em [de França et al. 2005]. Para isso, uma fórmula que depende do valor máximo de feromônio, número de medianas, número de centros e valor mínimo de feromônio é utilizada. Quando a soma do valores de feromônio presentes no vetor de feromônio atinge o valor retornado pela fórmula, o vetor de feromônio é reinicializado.
- Somente formigas que geram ótimos locais ou globais atualizam o vetor de feromônio.

¹<https://www.python.org/download/releases/3.0/>

²<http://www.numpy.org/>

4. ESTRUTURA DO PROJETO E EXECUÇÃO

Os arquivos de código-fonte do projeto se encontram na pasta **src**.

4.1. Parâmetros

A fim de facilitar a execução do programa, foram definidos parâmetros para alterar alguns pontos chave para Programação Dinâmica. São eles:

- **Arquivo de entrada:** Arquivo com os dados de entrada a serem usados pelo programa.
- **Semente:** Número inteiro usado na geração de números aleatórios durante a execução do programa. Note que, mantendo todos os outros parâmetros fixos, a saída do programa para uma mesma entrada e valor de semente será sempre igual. A semente da execução pode ser definida com a flag **-s** e tem valor padrão 0.
- **Número de formigas:** Número inteiro que determina o número total de formigas que serão utilizadas para gerar soluções do problema. Pode ser definido com a flag **-n** e tem valor padrão 4.
- **Número de iterações:** Define o número de iterações pelo qual o programa deve executar. Definido com a flag **-i** e tem valor padrão 10.
- **Taxa de evaporação de feromônio:** Taxa segundo a qual os valores de feromônio depositado nos centros desaparecem com o tempo. Definida com a flag **-d** e tem valor padrão 0.8.
- **Peso para feromônio (alpha):** Peso do feromônio no cálculo de probabilidade de escolher um centro. Definido com a flag **-a** e tem valor padrão 3.
- **Peso para heurística de informação (beta):** Peso da heurística de informação no cálculo de probabilidade de escolher um centro. Definido com a flag **-b** e tem valor padrão 1.

Para executar o programa, o comando abaixo é usado:

```
tp2.py [-h] [-n ANTEN] [-i MAXIT] [-d DECAYR] [-a ALPHA] [-b BETA] [-s RSEED]  
INPUT_FILE
```

Onde RSEED indica a semente, ANTEN o número de formigas, MAXIT o número de iterações do algoritmo, DECAYR a taxa de evaporação do feromônio, ALPHA e BETA os pesos de feromônio e heurística de informação, respectivamente), INPUT_FILE o nome do arquivo de entrada.

Todos os parâmetros entre colchetes acima são opcionais.

4.2. Entrada e Saída

Os arquivos de entrada devem possuir a mesma estrutura. Neles, a primeira linha deve conter os valores de n e p , separados por um espaço. Nas n linhas seguintes, são listados os dados dos centros, i.e., x , y , c e d , que são a coordenada x , coordenada y , capacidade c do centro e demanda d , respectivamente.

Em relação à saída do programa, é impresso, a cada iteração, o número da mesma e os valores de melhor solução global e local. Ao final é impresso o custo da melhor solução achada para o programa.

5. EXPERIMENTOS

Nessa seção serão apresentados os experimentos realizados. Todos eles foram executados em uma máquina Intel Core i7-5500U, 2.40GHz, 4 cores, 8GB de memória RAM e sistema operacional ubuntu 14.04 LTS.

5.1. Metodologia

Muitas instâncias de teste foram executadas para cada uma das bases de teste. A metodologia utilizada foi um processo iterativo de determinação de parâmetros ótimos para cada um dos três arquivos de entrada fornecidos com o trabalho. A cada etapa, um dos parâmetros era o foco do experimento, que procurava identificar configurações ótimas ou próximas disso.

Uma vez determinados esses parâmetros ótimos, seguia-se para o próximo parâmetro a determinar, fixando-se aqueles já determinados anteriormente.

5.2. Experimentos

Abaixo são mostrados os principais experimentos realizados. Os resultados são apresentados na Seção 6. Os valores apresentados foram obtidos da média de 30 execuções.

- **Experimento 1:** No primeiro experimento, objetivou-se simplesmente a verificação de qual número de formigas utilizado é mais interessante para cada arquivo de teste. Para os três, os parâmetros de execução foram:
Número de formigas: [10, 30, 60, 90]
Número de iterações: 50
Taxa de evaporação: 0.8
Alpha: 3
Beta: 1
- **Experimento 2:** Nesse segundo experimento, o objetivo foi verificar por quantas iterações o programa deveria ser executado para cada arquivo de teste. Os parâmetros utilizados para a execução foram os seguintes:
Número de formigas: Definido em Experimento 1.
Número de iterações: 100
Taxa de evaporação: 0.8
Alpha: 3
Beta: 1

6. RESULTADOS

6.1. Experimento 1: Número de formigas

Com esse experimento, conseguimos determinar o número de formigas mais apropriado para cada arquivo de teste. Mais apropriado aqui refere-se ao valor do parâmetro que mais compensa o custo de tempo e resultado obtido. Vemos por exemplo que, para o arquivo SJC1.dat, a variação no número de formigas causou também uma grande variação no resultado obtido, sendo, portanto, melhor o uso de 90 formigas.

Para o arquivo SJC2.dat, vemos que os valores de 60 e 90 formigas alcançam resultados muito similares, não sendo justificável o uso de 90 formigas, que acarreta em perda de desempenho.




Figura 2. Experimento 1 - SJC1.dat: Número de iterações x Ótimo global para quantidades variáveis de formigas. Cada cor representa uma quantidade de formigas utilizada.

Finalmente, para o arquivo SJC3.dat, os resultados obtidos para 30, 60 e 90 formigas são muito próximos, logo, para melhor desempenho em tempo, escolhemos o valor de 30 formigas.

6.2. Experimento 2: Iterações

Uma vez definido o número de formigas a ser utilizado para cada um dos arquivos teste, é necessário determinar por quantas iterações o programa deve executar para cada arquivo, uma vez que valores próximos do ótimo podem ser encontrados em uma iteração i , não sendo necessário executar o programa por mais que i iterações.

6.3. Observações

Os experimentos realizados possibilitaram observar diversas características importantes, tanto de otimização por colônia de formigas em geral quanto a respeito dos arquivos de entrada utilizados. Vimos aqui que a escolha do número de formigas, por exemplo, determina o nível de exploração do espaço de busca. Sendo cada uma das formigas responsável por seguir por um 'caminho' ao procurar soluções para o problema.

Importante notar que o trabalho seguiu o que foi feito em [de França et al. 2005], sendo assim, interessante em trabalhos relacionados que utilizem o algoritmo de colônia de formigas a utilização de outros trabalhos de referência, para fins de comparação em algum projeto futuro.




Figura 3. Experimento 1 - SJC2.dat: Número de iterações x Ótimo global para quantidades variáveis de formigas. Cada cor representa uma quantidade de formigas utilizada.

7. CONCLUSÃO

Com esse trabalho, os conceitos fundamentais de Otimização por Colônia de Formigas puderam ser fixados. A estrutura geral do algoritmo é muito simples e podemos perceber que os detalhes de implementação na verdade são muito dependentes do problema a ser resolvido. Também é importante notar que a modelagem do problema, mais uma vez, exerce papel fundamental tanto na performance quanto em complexidade de código e outros fatores.

Assim como no trabalho prático 1, a maior dificuldade foi a de lidar com o tempo demandado pela execução de experimentos. Cada instância do algoritmo, isto é, configuração de parâmetros a ser executada demora uma quantidade muito grande de tempo.

De maneira geral vemos que os valores de custo obtidos ao final do trabalho são muito bons quando comparados com os valores de ótimo fornecidos com as bases de teste. Logo, o algoritmo de colônia de formigas é realmente muito competitivo, principalmente tendo em mente que o problema da p-Mediana é NP-difícil.




Figura 4. Experimento 1 - SJC3b.dat: Número de iterações x Ótimo global para quantidades variáveis de formigas. Cada cor representa uma quantidade de formigas utilizada.

8. REFERÊNCIAS

Brownlee, J. (2011). *Clever Algorithms*. LuLu, 1st edition.

de França, F. O., Zuben, F. J. V., and de Castro, L. N. (2005). Max min ant system and capacitated p-medians: Extensions and improved solutions. *Informatica (Slovenia)*, 29(2):163–172.